

PROJET ECONOMETRIE

-

ANNA BENNAIM – CHLOE MARANGON

ANALYSE DE L'EVOLUTION DU TAUX DE NATALITE ENTRE 2013 ET 2023



En quoi le taux de chômage et le niveau de développement d'un pays peuvent-ils expliquer le taux de natalité observé ?

SOMMAIRE

I. INTRODUCTION

II. STATISTIQUES DESCRIPTIVE

A. Variables endogènes

B. Variables explicatives

1. X_1 : le taux de chômage

2. X_2 : le niveau de développement d'un pays

III. ESTIMATION DU MODÈLE PAR LES MCO

A. Résultats d'estimation

B. Significativité globale du modèle

C. Tests des coefficients

IV. TESTS

A. Test de Chow

B. Test d'ajout d'une nouvelle variable

V. CONCLUSION

« Je déclare sur l'honneur que ce mémoire a été rédigé de ma main, sans aide extérieure non autorisée, qu'il n'a pas été présenté auparavant pour évaluation et qu'il n'a jamais été publié, dans sa totalité ou en partie. Toutes parties, groupes de mots ou idées, aussi limités soient-ils, y compris des tableaux, graphiques, cartes etc. qui sont empruntés ou qui font référence à d'autres sources bibliographiques sont présentés comme tels, sans exception aucune. »

Chloé Marangon, Anna Bennaim, le 03/02/2024

I - INTRODUCTION

« C'est en comprenant les enjeux du taux de natalité que nous pourrons construire une société résiliente et dynamique pour les générations à venir » (Emmanuel Macron). Afin de mieux saisir les enjeux et causes du déclin mondial du taux de natalité au cours des dernières années, nous avons fait le choix d'étudier le taux de natalité, plus spécifiquement en 2023 dans 37 pays différents, répartis sur tous les continents.

De ce fait, nous allons étudier les différents facteurs expliquant l'évolution du taux de natalité.

En effet, depuis une dizaine d'années on observe que le nombre de naissances ne cesse de diminuer.

Même si la France reste un des pays avec le plus haut niveau de fécondité à l'échelle européenne, le nombre d'enfants par femme a atteint un seuil historique de 1,68 en janvier 2024.

Pour tenter de comprendre les mécanismes expliquant ce déclin, nous avons choisi le taux de natalité comme variable endogène ainsi que deux autres variables exogènes : le niveau de développement du pays ainsi que le taux de chômage observé. L'ensemble de ces variables sont observées en 2023 à l'échelle de trente-sept pays différents. Nous avons choisi des pays de tous les continents afin d'avoir une approche plus réaliste. Par conséquent, nous serons dans le cas d'un modèle en coupe instantanée.

Notre première variable exogène est le taux de chômage. En effet, la plupart des couples ne projettent d'avoir un bébé que lorsque leur situation est assez stable d'un point de vue sentimental mais aussi économique ou professionnel. Le chômage étant une forme de dégradation de la situation économique d'un couple, cela crée une forte instabilité et pourrait donc être un facteur expliquant une baisse du taux de natalité observé.

Le choix de notre seconde variable exogène a été le niveau de développement d'un pays. En effet, le niveau de développement d'un pays est directement lié à l'accès à l'éducation, à la protection sociale ou encore à l'accès à la contraception. Ces nombreux facteurs peuvent directement influencer le processus de procréation des individus. Dans les pays moins développés, l'absence d'accès à la contraception, les normes culturelles favorables à un nombre élevé d'enfants ou encore la forte mortalité infantile sont des facteurs qui contribuent à un taux de natalité élevé. De ce fait, il nous semble cohérent qu'un faible niveau de développement soit associé avec un taux de natalité élevé. Nous mesurerons cet aspect avec l'IDH (Indice de Développement Humain).

Par conséquent, dans ce projet, nous tenterons de répondre à la problématique suivante :


En quoi le taux de chômage et le niveau de développement d'un pays peuvent-ils expliquer le taux de natalité observé ?

II - STATISTIQUES DESCRIPTIVES

A – Variable endogène Y : le taux de natalité

Le taux de natalité est défini selon l'Insee comme « le rapport entre le nombre annuel de naissances vivantes et la population moyenne, sur une période et un territoire donné ». Ce taux est exprimé en pour mille, c'est à dire sur une base de 1000 personnes.

L'ensemble des valeurs relevées pour la variable endogène ont été collectées sur le site de l'INED ainsi que sur *Atlasocio*, les données de 2023 n'étant pas encore toutes disponibles sur le site de l'INED.



Statistiques descriptives, utilisant les observations 1 - 37 pour la variable « TauxdenatalitAen2023pour » (37 observations valides)

Moyenne	13.717
Médiane	10.370
Minimum	5.1500
Maximum	40.850

Au premier abord, nous pouvons remarquer que le taux de natalité moyen de notre échantillon était de 13,7 par mile en 2023. De plus, notre échantillon possède une grande amplitude entre la valeur maximale et minimale (35,7 par mile) traduisant une forte disparité du taux de natalité à l'échelle mondiale.


A- Variable explicative X_1 : Le taux de chômage

Notre première variable explicative mesure le niveau de chômage en 2023, à l'échelle de nos 37 pays sélectionnés.

Le taux de chômage désigne le rapport entre le nombre de chômeurs et la population active, soit le nombre de personnes en âge de travailler disponible sur le marché du travail. Ce nombre est exprimé en pourcentage donc rapporté à une base de 100.

Nos données sont tirées de *la Banque mondiale* et complétées par *Trading economics*.

Moyenne	7.9414
Médiane	6.3000
Minimum	0.10000
Maximum	53.460
Écart-type	8.9312




On observe avec GRETL que le coefficient de corrélation entre le taux de chômage et le taux de natalité est égal à 0,15. Ces deux variables sont donc très faiblement corrélées puisque ce coefficient se rapproche de 0 donc d'une absence de corrélation. Nous pouvons donc penser que l'évolution du taux de chômage n'accompagne pas une variation du taux de natalité.

B- Variable explicative X_2 : Le niveau de développement d'un pays.

Notre seconde variable explicative mesure le niveau de développement d'un pays et plus précisément l'IDH (Indice de Développement Humain) en 2023, à l'échelle des 37 pays étudiés.

L'IDH est un indice prenant en compte trois dimensions du développement : la santé mesurée par l'espérance de vie à la naissance, l'éducation mesurée par la durée moyenne de scolarité et enfin le niveau de vie mesuré par le PIB (Produit Intérieur Brut) reflétant le revenu moyen par personne dans un pays. L'IDH est noté entre 0 et 1 et plus cette note est proche de 1, plus le niveau de développement du pays est élevé.

L'ensemble de nos données sont extraites de *la banque mondiale* ainsi que de *Atlasocio*.



On observe avec Gretl que le coefficient de corrélation entre le taux de natalité et le niveau de développement du pays est égal à -0,85. Ce coefficient de corrélation est négatif : ces deux variables sont donc reliées négativement, une augmentation de l'une entrainera donc une diminution en valeur de l'autre. Ce coefficient est relativement élevé en valeur absolue donc la corrélation est significativement différente de 0. Par conséquent, plus le niveau de développement augmente, plus le taux de natalité baisse.

Enfin, on obtient que le coefficient de corrélation théorique est : $r_{x,y} = \frac{n \sum x_i y_i - \sum x_i \sum y_i}{(n \sum x_i^2 - (\sum x_i)^2)^{0.5} * (n \sum y_i^2 - (\sum y_i)^2)^{0.5}}$

```
corr(TauxdechAmageen2023, niveaudedeveloppement) = -0.26572750
```

Ainsi, grâce à Gretl, on retrouve : $r_{X_1, X_2} = -0,266$. Le coefficient est très proche de 0 et est négatif, cela montre que nos deux variables explicatives sont faiblement et négativement corrélées.

III - ESTIMATION DU MODÈLE PAR LES MCO

A- Les résultats d'estimation

gretl : modèle 10				
Fichier Édition Tests Enregistrer Graphiques Analyse LaTeX				
Modèle 10: MCO, utilisant les observations 1-37				
Variable dépendante: TauxdenatalitAen2023pour				
	coefficient	éc. type	t de Student	p. critique
const	52.2567	4.22322	12.37	3.83e-14 ***
TauxdechAmageen2~	-0.0727030	0.0809187	-0.8985	0.3753
niveaudedevelopp~	-47.5071	4.94301	-9.611	3.19e-11 ***
Moyenne var. dép.	13.71730	Éc. type var. dép.	7.922985	
Somme carrés résidus	594.1492	Éc. type régression	4.180308	
R2	0.737085	R2 ajusté	0.721619	
F(2, 34)	47.65969	P. critique (F)	1.37e-10	
Log de vraisemblance	-103.8607	Critère d'Akaike	213.7213	
Critère de Schwarz	218.5541	Hannan-Quinn	215.4251	

Tout d'abord, nous allons effectuer une première estimation de notre modèle par la méthode des moindres carrés ordinaires (MCO) à l'aide du logiciel Gretl. Pour le créer, nous avons pris comme variable dépendante notre variable Y explicative : le taux de natalité et une régression multiple sur nos deux variables explicatives, X_1 : le taux de chômage et X_2 : le niveau de développement du pays. Donc l'estimation du modèle nous donne :

$$Y = 52.26 - 0.073 X_1 - 47.51 X_2 + e_t$$

Le modèle semble être significatif et montre une corrélation négative entre nos deux variables explicatives. De plus, la variable X_2 semble significativement expliquer Y . Par ailleurs, le coefficient de corrélation entre X_1 et Y étant proche de 0, nos tests devraient montrer que X_1 n'est pas significativement explicative de Y .

B- La significativité globale du modèle :

Dans cette section, nous allons effectuer un test de significativité globale de notre modèle. Ce test est un test de Fisher et permet de déterminer si l'ensemble des variables explicatives prises simultanément peut expliquer les variations de la variable dépendante.

- Premièrement, nous posons les hypothèses de ce test :

$$\begin{cases} H_0 : a_1 = a_2 = 0 : \text{Tous les paramètres du modèle sont nuls sauf } a_0. \\ H_1 : \text{Il existe au moins un des deux coefficients significativement différent de 0.} \end{cases}$$

- Deuxièmement, nous allons calculer la statistique du test, notée F^* tel que

$$F^* = \frac{SCE/ddl_{SCE}}{SCR/ddl_{SCR}} = \frac{\sum_{i=1}^n (\hat{y}_t - \bar{y})/k}{\sum_{i=1}^n e_t^2 / (n - k - 1)} = \frac{R^2/k}{(1 - R^2)/(n - k - 1)}$$

De plus, $F^* = \frac{R^2/k}{(1-R^2)/(n-k-1)} \longrightarrow F(k, n-k-1)$

Avec R^2 : le coefficient de détermination ; k : le degré de liberté de SCE et $n-k-1$: le degré de liberté de SCR

- Enfin, on applique la règle de décision : on compare F^* à sa valeur critique notée $F^{\alpha}_{(k, n-k-1)}$ au seuil $\alpha = 5\%$.
 -Si $F^* > F^{\alpha}_{(k, n-k-1)}$, H_0 est rejetée, le modèle est globalement explicatif
 -Si $F^* \leq F^{\alpha}_{(k, n-k-1)}$, H_0 n'est pas rejetée, la régression n'est pas globalement significative.
- En utilisant Gretl, on obtient que $R^2 = 0,737$ (pour $k=2$; $n=37$). Ainsi, en appliquant la formule on trouve $F^* = 47,64$.
- Enfin, en allant chercher dans la table de Fischer, on obtient $F^{0,05}_{(2,34)} \in [3,23 ; 3,32]$ (imprécision de lecture dans la table).
- En comparant ces résultats, on obtient que $F^* > F^{0,05}_{(2,34)}$. On rejette donc H_0 au seuil de 5%. Nous pouvons en déduire que notre modèle est globalement significatif. Ainsi, on accepte H_1 ce qui signifie qu'au moins un de nos coefficients possède une influence significative sur la variable dépendante Y , le taux de natalité.

C- Tests des coefficients :

Nous allons à présent effectuer des tests de Student sur chaque coefficient de nos variables explicatives. Nous allons commencer par X_1 , la variable explicative associée au taux de chômage de chaque pays en 2023. Nous notons le coefficient de cette variable a_1 .

○ Coefficient a_1 :

$\hat{a}_1 = -0.073 < 0$ On remarque ainsi que le taux de chômage a une influence négative sur le taux de natalité, comme supposé dans nos hypothèses. De plus, si le taux de chômage augmente de 1, alors Y diminue de 0.073 unité. Comme ce coefficient est proche de 0, il n'est pas significatif au vu de sa taille négligeable.

- Posons les hypothèses de ce test. Ici nous voulons savoir si le coefficient a_1 est significatif :

$$\begin{cases} H_0 : a_1 = 0 \\ H_1 : a_1 \neq 0 \end{cases}$$

- La statistique du test (Ratio de Student) : $t^* = \frac{\hat{a}_1 - a_1}{\hat{\sigma}_{\hat{a}_1}} = \frac{\hat{a}_1}{\hat{\sigma}_{\hat{a}_1}}$ (sous H_0) $\longrightarrow t(n-k-1)$
- Avec un risque de première espèce $\alpha=0,05$, la règle de décision est : on compare t^* avec sa valeur critique $t_{n-k-1}^{\alpha/2}$.
 - si $|t^*| > t_{n-k-1}^{\alpha/2}$ alors H_0 est rejetée : a_1 est significativement différent de 0.
 - si $|t^*| \leq t_{n-k-1}^{\alpha/2}$ alors H_0 n'est pas rejetée : a_1 n'est pas significativement différent de 0.
- Grace à Gretl, nous pouvons utiliser les valeurs numériques pour faire ce test. On obtient que $\hat{a}_1 = -0,07$; $\hat{\sigma}_{\hat{a}_1} = 0,08$, toujours pour $n=37$ et $k=2$.
Ainsi, $t^* = -0,875$. Par ailleurs, en cherchant dans la table de Student, on a $t_{34}^{0,05/2} = 1,96$ (on utilise la loi normale car $34 > 30$).
- Pour conclure, on a $|t^*| < t_{34}^{0,05/2}$, donc on ne rejette pas H_0 au seuil de 5%. Ce test indique que le coefficient a_1 de notre variable X_1 : le taux de chômage, n'est pas significativement différent de 0. Ainsi, le taux de chômage (X_1) n'explique pas significativement Y , le taux de natalité.

De plus, nous allons effectuer exactement le même test mais pour le coefficient a_2 de la variable explicative X_2 (le niveau de développement de chaque pays en 2023).

○ Coefficient a_2 :

- Posons les hypothèses de ce test : ici nous voulons savoir si le coefficient a_2 est significatif.

$$\begin{cases} H_0 : a_2 = 0 \\ H_1 : a_2 \neq 0 \end{cases}$$
- La statistique du test, notée t^* : $t^* = \frac{\hat{a}_2 - a_2}{\hat{\sigma}_{\hat{a}_2}} = \frac{\hat{a}_2}{\hat{\sigma}_{\hat{a}_2}}$ (sous H_0) $\longrightarrow t(n-k-1)$
- La règle de décision, avec un risque de première espèce $\alpha=0,05$: on compare t^* avec sa valeur critique $t_{n-k-1}^{\alpha/2}$.
 - si $|t^*| > t_{n-k-1}^{\alpha/2}$ alors H_0 est rejetée : a_2 est significativement différent de 0.
 - si $|t^*| \leq t_{n-k-1}^{\alpha/2}$ alors H_0 n'est pas rejetée : a_2 n'est pas significativement différent de 0.
- Grace à Gretl, nous pouvons utiliser les valeurs numériques pour faire ce test. On obtient que $\hat{a}_2 = -47,51$; $\hat{\sigma}_{\hat{a}_2} = 4,94$ et toujours $n=37$ et $k=2$.
Ainsi, $t^* = -9,62$. En outre, en cherchant dans la table de Student, on a $t_{34}^{0,05/2} = 1,96$ car $34 > 30$ donc on utilise la loi normale.
- Pour conclure, on a $|t^*| > t_{34}^{0,05/2}$, donc on rejette H_0 au seuil de 5%. Nous pouvons en déduire que ce test indique que le coefficient a_2 de notre variable X_2 : le niveau de développement de chaque pays, est significativement différent de 0. La variable X_2 contribue donc significativement à expliquer notre variable explicative Y , le taux de natalité.

On observe que $\hat{a}_2 = -47,51 < 0$. Ainsi, une augmentation du niveau de développement s'accompagne donc de la diminution du taux de natalité, comme espéré. De plus, si le niveau de développement augmente de 1, alors Y diminue d'environ 48 unités. Comme ce coefficient est important, il est significatif au vu de sa taille conséquente.

Ainsi, ce résultat nous semble assez logique. Le niveau de développement d'un pays est une variable importante à prendre en compte lorsqu'on envisage de concevoir un enfant. En effet, avoir des enfants dans des pays en développement ou peu développé est perçu comme une richesse. Par ailleurs dans ces pays, contrairement aux pays développés, la contraception est souvent peu répandue voire inexistante. De plus, les enfants sont souvent soumis au travail et sont donc une source de revenus pour leurs parents. Une dernière explication est le taux de mortalité infantile élevé. Lorsque deux couples ont six ou sept enfants, généralement moins de la moitié de ces enfants survivent.

Par ailleurs, contrairement à ce que l'on pensait, le taux de chômage ne permet pas d'expliquer le taux de natalité d'un pays. Cette citation nous l'illustre bien « La population active des Pays-Bas progresse

aussi vite, et son taux de chômage reste l'un des plus bas d'Europe, souligne Anne Sonnet, de l'OCDE. Il faut se méfier des raisonnements arithmétiques et simplistes. »

Enfin, nous allons conclure ces tests sur les coefficients avec un dernier test de Student. Dans ce test, nous voulons savoir si les coefficients a_1 et a_2 sont significativement différents l'un de l'autre.

Hypothèses :

$$\begin{cases} H_0 : a_1 = a_2 \\ H_1 : a_1 \neq a_2 \end{cases} \Leftrightarrow \begin{cases} H_0 : a_1 - a_2 = 0 \\ H_1 : a_1 - a_2 \neq 0 \end{cases}$$

On pose $a_1 - a_2 = d$

- La statistique du test, notée t^* est : $t^* = \frac{\hat{d} - d}{\hat{\sigma}_{\hat{d}}} = \frac{\hat{d}}{\hat{\sigma}_{\hat{d}}} \text{ (sous } H_0) \longrightarrow t(n-k-1)$
- Règle de décision : avec un risque de première espèce $\alpha=0,05$, on compare t^* avec sa valeur critique $t_{n-k-1}^{\alpha/2}$.
 - si $|t^*| > t_{n-k-1}^{\alpha/2}$ alors H_0 est rejetée : d est significativement différent de 0 et donc les coefficients a_1 et a_2 sont significativement différents.
 - si $|t^*| \leq t_{n-k-1}^{\alpha/2}$ alors H_0 n'est pas rejetée : d n'est pas significativement différent de 0 et donc a_1 et a_2 ne sont pas significativement différents.

On génère ensuite la matrice de covariance $\hat{\Omega}_{\hat{a}}$ avec

$$\text{Gretl : } \hat{\Omega}_{\hat{a}} = \hat{\sigma}_{\varepsilon}^2 (X'X)^{-1}$$

Matrice de covariance des coefficients de régression:

const	TauxdechAmagee~	niveaudevelo~	const
17.8356	-0.13693	-20.3683	const
	0.00654783	0.106286	TauxdechAmagee~
		24.4333	niveaudevelo~

On calcule $\hat{\sigma}_{\hat{a}_1 - \hat{a}_2} = (\hat{\sigma}_{\hat{a}_1}^2 + \hat{\sigma}_{\hat{a}_2}^2 + 2 * (1) * (-1) * \text{Cov}(\hat{a}_1, \hat{a}_2))^{0.5} = (0,006548 + 24,433 - 2 * 0,1063)^{0.5} = 4,922$

Comme $\hat{a}_1 = -0,073$ et $\hat{a}_2 = -47,51$

Ainsi, on obtient : $t^* = 9,45$

- En outre, en cherchant dans la table de Student pour $n=37$ et $k=2$, on a $t_{34}^{0,05/2} = 1,96$ (comme $34 > 30$ on utilise la loi normale). Pour conclure, on a $|t^*| > t_{34}^{0,05/2}$, donc on rejette H_0 au seuil de 5%. Nous pouvons en conclure que les coefficients a_1 et a_2 sont significativement différents l'un de l'autre.

IV- TESTS

A - Test de Chow :

Nous sommes dans le cas d'une coupe instantanée. Ce test va nous permettre de déterminer si le modèle est homogène pour l'ensemble de l'échantillon ou si nous devons considérer deux sous échantillons distincts.

D'après le test de Chow effectué sur Gretl, nous devons diviser notre modèle en deux échantillons. Cela signifie que les taux de natalités relevés ne sont pas homogènes. On considère deux échantillons :

- Du 1er au 19^{ème} pays : où le taux de natalité varie entre 40,85 et 10,73.
- Du 20^{ème} au 37^{ème} pays : où le taux de natalité est inférieur à 10,37 et atteint même 5,15.

Une explication justifiant la séparation de notre échantillon en deux sous-groupes est que les pays compris dans le premier échantillon ont un taux de natalité élevé compris supérieur à 10,73 tandis que dans le deuxième échantillon, les pays sont majoritairement occidentaux avec un taux de natalité plus faible, inférieur à 10,37. On obtient une médiane de Y égale à 10,365.

En utilisant Gretl, les modèles à estimer sont donc :

Modèle 1 : $y = a_0 + a_1 x_1 + a_2 x_2 + \varepsilon$ pour $i=1,...,37$

Modèle 1 :

```
? smpl Y<10.365 --restrict
Plage des données complète: 1 - 37 (n = 37)
Echantillon actuel: 1 - 19 (n = 19)

? ols Y const X1 X2

Modèle 1: MCO, utilisant les observations 1-19
Variable dépendante: Y
```

	coefficient	éc. type	t de Student	p. critique
const	53.2651	4.78772	11.13	6.11e-09 ***
X1	-0.0717242	0.0892198	-0.8039	0.4332
X2	-47.0569	6.16821	-7.629	1.02e-06 ***

Moyenne var. dép.	18.44947	Éc. type var. dép.	8.671545
Somme carrés résidus	291.4587	Éc. type régression	4.268041
R2	0.784667	R2 ajusté	0.757750
F(2, 16)	29.15167	P. critique (F)	4.62e-06
Log de vraisemblance	-52.89920	Critère d'Akaike	111.7984
Critère de Schwarz	114.6317	Hannan-Quinn	112.2779

Modèle 2:

```
? smpl Y<10.365 --restrict
Plage des données complète: 1 - 37 (n = 37)
Echantillon actuel: 20 - 37 (n = 18)

? ols Y const X1 X2

Modèle 2: MCO, utilisant les observations 20-37 (n = 18)
Variable dépendante: Y
```

	coefficient	éc. type	t de Student	p. critique
const	1.91569	2.87596	0.6661	0.5155
X1	-0.195105	0.0426024	-4.580	0.0004 ***
X2	9.01325	3.18617	2.829	0.0127 **

Moyenne var. dép.	8.722222	Éc. type var. dép.	1.366410
Somme carrés résidus	8.895787	Éc. type régression	0.770899
R2	0.719732	R2 ajusté	0.682363
F(2, 15)	19.26012	P. critique (F)	0.000072
Log de vraisemblance	-19.19775	Critère d'Akaike	44.39550
Critère de Schwarz	47.06661	Hannan-Quinn	44.76381

$y_1 = a_0^1 + a_1^1 x_1 + a_2^1 x_2 + \varepsilon$ pour $i=1,...,19$.

$y_2 = a_0^2 + a_1^2 x_1 + a_2^2 x_2 + \varepsilon$ pour $i=20,...,37$

Ainsi, on obtient :

- Les hypothèses :

$H_0 : SCR = SCR_1 + SCR_2$, avec: SCR=somme des carrés des résidus du modèle complet $H_1 : SCR \neq SCR_1 + SCR_2$	SCR_1 =somme des carrés des résidus du modèle 1 SCR_2 = somme des carrés des résidus du modèle 2
--	---
- Statistique de Test :

$$\text{Sous } H_0, \quad F^* = \frac{(\hat{SCR} - SCR_1 - SCR_2)/(k+1)}{(SCR_1 + SCR_2)/(n-2k-2)} \sim F_{(k+1; n-2k-2)}$$

$$F^* = \frac{(594.1492 - 291.4587 - 8.8958)/3}{(291.4587 + 8.8958)/(37-4-2)} = 10,1077$$

Avec : $k=2$, $n=37$; $SCR=594.1492$; $SCR_1=291.4587$; $SCR_2=8,8958$

- Règle de décision : On compare F^* avec $F^{0.05}_{(k+1, n-2(k+1))} = F^{0.05}_{(3,31)} \in [2,84 ; 2,92]$
 On a que $F^*=10,1077$ est bien plus grand que $F^{0.05}_{(3,31)}$. Ainsi, comme $F^* > F^{0.05}_{(3,31)}$, H_0 est rejetée au seuil $\alpha = 5\%$.
 L'hypothèse H_1 est donc privilégiée, ce qui signifie que notre modèle affiche une rupture de tendance. De ce fait, l'effet des variables explicatives sur le taux de natalité est différent dans chaque modèle. Nous pouvons conclure que pour étudier la variation du taux de natalité de manière plus précise, il serait préférable de diviser le modèle en deux.

De plus, la p-value calculée avec Gretl confirme cette décision :

Test de Chow pour rupture structurelle à l'observation 19
 $F(3, 31) = 9.93411$ avec p. critique 0.0001

B - Test d'ajout de variable :

Nous allons, à présent, procéder au dernier test sur notre modèle, qui est le test d'ajout d'une variable explicative. On va comparer deux modèles :

- $y_t = a_0 + a_1 x_{1,t} + a_2 x_{2,t} + \varepsilon_t$: le modèle de non-contrainte
- $y_t = a_0 + a_2 x_{2,t} + \varepsilon_t$: le modèle contraint

Avec en fonction de notre modèle Y : le taux de natalité ; X_1 : le taux de chômage ; et X_2 le niveau de développement du pays.

- L'hypothèse de ce test est : $H_0 : a_1 = 0$
 $H_1 : a_1 \neq 0$
- La statistique du test : on utilise le test de restrictions et de contraintes sur les coefficients :

$$F^* = \frac{(SCR^c - SCR^{nc})/q}{\frac{SCR^{nc}}{n - k - 1}}$$

	coefficient	éc. type	t de Student	p. critique
const	52.2567	4.22322	12.37	3.83e-14 ***
niveaudedevelopp~	-47.5071	4.94301	-9.611	3.19e-11 ***
TauxdechAmageen2~	-0.0727030	0.0009187	-0.8985	0.3753

Moyenne var. dép.	13.71730	Éc. type var. dép.	7.922985
Somme carrés résidus	594.1492	Éc. type régression	4.180308
R2	0.737085	R2 ajusté	0.721619
F(2, 34)	47.65969	P. critique (F)	1.37e-10
Log de vraisemblance	-103.8607	Critère d'Akaike	213.7213
Critère de Schwarz	218.5541	Hannan-Quinn	215.4251

Modèle de Non-Contrainte :

	coefficient	éc. type	t de Student	p. critique
const	50.7363	3.85871	13.15	4.21e-15 ***
niveaudedevelopp~	-46.3270	4.75216	-9.749	1.64e-11 ***

Moyenne var. dép.	13.71730	Éc. type var. dép.	7.922985
Somme carrés résidus	608.2558	Éc. type régression	4.168781
R2	0.730843	R2 ajusté	0.723153
F(1, 35)	95.03552	P. critique (F)	1.64e-11
Log de vraisemblance	-104.2948	Critère d'Akaike	212.5895
Critère de Schwarz	215.8114	Hannan-Quinn	213.7254

Modèle de Contrainte :

Grace aux données de Gretl, on obtient $F^* = \frac{(608,26 - 594,15)/1}{\frac{594,15}{34}} = 0,81$

Avec : $q = 1 =$ nombre de contraintes sous H_0 ; $k=2$ et $n=37$

- Règle de décision : on compare F^* à $F_{(q,n-k-1)}^{\alpha} = F_{(1,34)}^{0,05} \in [4,08 ; 4,17]$. Ainsi on remarque que $F^* < F_{(1,34)}^{0,05}$, donc H_0 n'est donc pas rejetée au seuil $\alpha = 5\%$. On privilégie le modèle à une seule variable explicative. Ajouter la variable qui prend en compte le taux de chômage donc X_1 , n'améliore pas significativement la qualité d'ajustement du modèle, comparativement au modèle à X_2 seul.

V- CONCLUSION

A travers les différents résultats observés, nous pouvons déduire que notre modèle est globalement significatif. En effet, comme posé dans nos hypothèses, nous avons bien observé une corrélation négative entre nos deux variables explicatives ainsi qu'entre le niveau de développement et la variable expliquée, le taux de natalité. Cependant, la variable explicative taux de chômage ne permet pas d'expliquer significativement les variations du taux de natalité.

Comme vu dans le cours, la non-significativité du coefficient associé au taux de chômage peut soit être due à une colinéarité entre les variables explicatives soit à l'absence de corrélation entre Y et la variable explicative X_1 . Après avoir menés nos tests, nous pouvons affirmer que la non-significativité du taux de chômage est due à une quasi-absence de corrélation entre le taux de chômage et le taux de natalité.

Malgré la significativité de notre modèle, le test de Chow nous a montré une rupture de tendance entre les 19 premiers pays et les 18 derniers, montrant qu'une étude du taux de natalité en deux sous échantillons serait plus significative.

De plus, une étude du coefficient de détermination R^2 montre que 73,71% de la variabilité du taux de natalité est expliquée par notre modèle, c'est-à-dire X_1 et X_2 . Même si cette proportion semble importante, elle indique tout de même que près de 30% de la variation du taux de natalité reste inexpliquée dans ce modèle.

Pour conclure, nous pouvons affirmer que le modèle le plus représentatif est le modèle excluant la variable X_1 , le taux de chômage. Cependant, l'ajout d'une autre variable plus appropriée pourrait encore améliorer ce dernier modèle (sans X_1). Ceci sera l'objet principal de la seconde partie de notre projet.

Une critique apportée à ce projet repose sur la banque de données recueillie. L'échantillon de données est assez imprécis puisque au sein de l'année 2023 les valeurs observées fluctuent selon les mois. Les données disponibles sur internet n'étant pas toujours détaillées pour les 12 mois, nous n'avons pas toujours pu prendre comme valeur la moyenne des 12 résultats par année.

Bibliographie :

https://www.challenges.fr/magazine/la-natalite-n-est-pas-mere-du-chomage_336773

<https://www.ined.fr/fr/tout-savoir-population/chiffres/tous-les-pays-du-monde/>

<https://www.insee.fr/fr/statistiques/2381868#tableau-figure1>

<https://perspective.usherbrooke.ca/bilan/servlet/BMTendanceStatPays?langue=fr&codePays=FRA&codeTheme=1&codeStat=SP.DYN.CBRT.IN>

<https://donnees.banquemondiale.org/indicateur/SP.DYN.CBRT.IN>

<https://atlasocio.com/classements/economie/developpement/classement-etats-par-indice-de-developpement-humain-monde.php>

<https://fr.tradingeconomics.com/country-list/unemployment-rate>

<https://www.publicsenat.fr/actualites/societe/mal-choisi-reactionnaire-fascisant-le-rearmement-demographique-de-macron-passe-mal>